



فن تعليم الآلة

القسم الثاني : التوقع

المعادلة العمودية

محتويات الكورس :

- القسم الأول : مقدمة
- القسم الثاني : التوقع Regression
- القسم الثالث : التقسيم Classification
- القسم الرابع : الشبكات العصبية NN
- القسم الخامس : نظام الدعم الالي SVM
- القسم السادس : التعليم بدون اشراف Unsupervised ML
- القسم السابع : مواضيع هامة (القيم الشاذة , نظام الترشيحات ...)

Linear Regression Equation معادلة التوقع الخطي

Hypothesis: $h_{\theta}(x) = \theta_0 + \theta_1 x$

Parameters: θ_0, θ_1

Cost Function: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

Goal: $\underset{\theta_0, \theta_1}{\text{minimize}} J(\theta_0, \theta_1)$

- الهدف تقليل الفارق بين قيمة $h(x)$ و هي القيمة المتوقعة من المعادلة الخطية و قيمة y و هي القيمة الحقيقية
- يتم القسمة علي $2m$ لربط قيمة الخطا بعدد القيم بالعينة
- الهدف ايجاد قيم θ_0 و θ_1 والتي تجعل من J (نسبة الخطا) اقل ما يمكن
- تسمى احيانا Cost error function

Linear Regression Equation معادلة التوقع الخطي

Theta0 = 5 , theta 1 = 2

Equation $h(x) = 5 + 2x$


X	Y	h(x)	h(x) - y	(h(x) - y) ²
1	7	7	0	0
2	8	9	1	1
2	7	9	2	4
3	9	11	2	4
4	11	13	2	4
5	10	15	5	25
5	12	15	3	9

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J = 1 / 14 (0+1+4+4+4+25+9)$$

$$J = 47/14 = 3.3$$


الخط الأكثر ملائمة Best fit line



تحديد قيمة ثيتا


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)




$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)



الإنحدار التدريجي Gradient Descent



الانحدار التدريجي :

- طالما نحن نبحث عن قيم ثيتا 0 و 1 التي ستقلل قيمة J بأقصى قدر , فسنفرض قيم لثيتا 1 و 2 , ثم نقوم بتقليلها تدريجيا حتي نصل لأقل قيمة لـ J


$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m ((h_{\theta}(x_i) - y_i)x_i)$$


المعادلة العمودية Normal Equation

مفهوم القيم العظمي و الصغري

- اي منحني تصاعدي , تكون قيمة التفاضل موجبة




- اي منحني هابط , تكون قيمة التفاضل سالبة



- اي قيمة صغري او كبري تكون قيمة التفاضل صفر

المعادلة العمودية Normal Equation




مفهوم القيم العظمي و الصغري

- اي منحنى تصاعدي , تكون قيمة التفاضل موجبة
- اي منحنى هابط , تكون قيمة التفاضل سالبة
- اي قيمة صغري او كبري تكون قيمة التفاضل صفر

المعادلة العمودية Normal Equation

مفهوم القيم العظمي و الصغري

- تتواجد عندما يكون التفاضل يساوي صفر



المعادلة العمودية Normal Equation

طريقة الـ Normal Equation

- وهي عن طريق الاعتماد علي تفاضل الـ J و مساوتها بالصفر لايجاد قيمة الثيتا المطلوبة
- و اذا كان لدينا جدول مثل هذا لاكثر من متغير , فبعد مفاضلتها و مساوتها بالصفر ستكون الثيتا كالتالي

$$\theta = (X^T X)^{-1} X^T y$$

المعادلة العمودية Normal Equation

X_1	X_2	X_3	Y
العمر	القدرة	الاسطوانات	السعر
5	20	6	114
5	35	6	120
6	38	8	123
7	40	8	121
7	46	10	135

X_1	X_2	X_3	
1	1	1	
5	5	6	
20	35	38	Y
6	6	8	114
			120
X_4	X_5		123
			121
1	1		135
7	7		
40	46		
8	10		

Normal Equation المعادلة العمودية

$$\theta = (X^T X)^{-1} X^T y$$

X	1	5	20	6
	1	5	35	6
	1	6	38	8
	1	7	40	8
	1	7	46	10

X ^T	1	1	1	1	1
	5	5	6	7	7
	20	35	38	40	46
	6	6	8	8	10

Normal Equation المعادلة العمودية

$X^T X$	5	30	179	38
	30	184	1105	234
	179	1105	6785	1414
	38	234	1414	300

Normal Equation المعادلة العمودية

$X^T X$	5	30	179	38
	30	184	1105	234
	179	1105	6785	1414
	38	234	1414	300

$(X^T X)^{-1}$	10.4	-2.6	0.05	0.4
	-2.6	1.3	-0.02	-0.5
	0.05	-0.02	0.008	-0.02
	0.46	-0.5	-0.02	0.54

Normal Equation المعادلة العمودية

$$(X^T X)^{-1} X^T$$

10.4	-2.6	0.05	0.4
-2.6	1.3	-0.02	-0.5
0.05	-0.02	0.008	-0.02
0.46	-0.5	-0.02	0.54

Normal Equation المعادلة العمودية

$$(X^T X)^{-1} X^T$$

10.4	-2.6	0.05	0.4
-2.6	1.3	-0.02	-0.5
0.05	-0.02	0.008	-0.02
0.46	-0.5	-0.02	0.54

1	1	1	1	1
5	5	6	7	7
20	35	38	40	46
6	6	8	8	10

Normal Equation المعادلة العمودية

$$(X^T X)^{-1} X^T$$

0.8	1.55	-0.1	-2.6	-1.5
0.5	0.2	0.4	1.7	0.58
-0.01	0.11	0.074	0.07	0.078
0.8	0.5	1.02	0.48	1.44

Normal Equation المعادلة العمودية

$$(X^T X)^{-1} X^T Y$$

0.8	1.55	-0.1	-2.6	-1.5	114
0.5	0.2	0.4	1.7	0.58	120
-0.01	0.11	0.074	0.07	0.078	123
0.8	0.5	1.02	0.48	1.44	121
					135

Normal Equation المعادلة العمودية

$$(X^T X)^{-1} X^T Y$$

0.8	1.55	-0.1	-2.6	-1.5	114	-252.2
0.5	0.2	0.4	1.7	0.58	120	414.2
-0.01	0.11	0.074	0.07	0.078	123	40.162
0.8	0.5	1.02	0.48	1.44	121	529.14
					135	

المعادلة العمودية Normal Equation

أيهما أفضل : الـ Gradient Descent ولا الـ Normal Equation :

- الـ Normal Equation ميزتها ان مش محتاج تحسب قيمة الفا , و مش هتعمل خطوات كثير , هي خطوة واحدة
- بس عيبها انها بتكون صعبة و بطيئة جدا مع عدد كبير للـ features اللي هي n لان الماتركس هتكون مخيفة خاصة لعمل الـ inverse , فلو عدد الـ n يقل عن 10 الاف خليك في الـ Normal Equation , لو زادت يبقى لازم الـ Gradient Descent
- كمان فيه خوارزميات (زي linear regression) مش هينفع تشتغل الا بالـ Gradient Descent , و خوارزميات تانية ممكن الـ Normal Equation , ف لازم تكون عارف الاتنين و تشوف مين مناسب لايه

المعادلة العمودية Normal Equation

أحيانا بتحصل مشكلة في نوع النورمال , ان مصفوفة $X^T X$ في اكس تكون singular و معناها ان مش هينفع يتعمل لها inverse , وده هيعمل مشكلة

غالبا بيكون سبب انها singular حاجة من اتنين

- ان عدد الـ m (عدد الصفوف) اقل من عدد الـ n (العواميد او المعلومات عن كل بيت) خاصة لو الفرق كبير , فا اما تمسح شوية عواميد مش مهمة , او تزود بيانات و صفوف , او تشوف نوع ثاني
- اما يكون فيه عمودين معتمدين علي بعض , يعني فيه مثلا مساحة البيت بالمتر المربع , ومساحة البيت بالقدم المربع , وده معناه ان فيه عمود كامل يساوي عمود ثاني مضروب في فاكتر , وده هيوذي ان قيمة الماتركس كلها تساوي صفر , فالـ inverse مش هيعمل

المعادلة العمودية Normal Equation

X_1	X_2	X_3	X_4	Y
مساحة (متر) ²	مساحة (قدم) ²	عدد الغرف	هل به غاز طبيعي	السعر
110	1185	6	0	114
125	1345	6	0	120
129	1388	8	0	123
130	1400	8	0	121
137	1474	10	0	135